

CLIME: 跨模态市场信息注入的股票排序模型*

深度学习基础课程大作业

费维瀚 (PB24000347)

赵瀚焜 (PB24000385) 寇之洲 (PB24000354)

2026 年 6 月 14 日

摘要

本项目研究的是 A 股日频选股中的**横截面排序信号**：在每日约 4000–5000 只可交易股票中，模型需要判断哪些股票相对更值得进入 top-20 组合。我们不把任务简化为单股次日收益的精确回归，也不声称构建了完整的真实交易系统；本文的核心评估对象是模型在 holdout 集上的排序能力和选股信号质量，交易成本、滑点、换手约束等执行层因素作为后续交易策略模块处理。基于这一设定，本文提出 **CLIME** (Cross-Modal Injection via Learned Market Encoding)，一种面向股票排序的 Transformer 架构。模型通过两阶段训练先学习 pairwise 排序先验，再使用方向感知回归损失进行精调；同时，ScaledGatedEncoder 将同业动态 (peer dynamics) 和市场上下文以受控加法方式注入 Backbone 表征，使市场信息作为增量修正而非直接覆盖个股判断。

在 holdout 测试集 (2025 年 12 月至 2026 年 5 月, 100 个交易日) 上, CLIME 取得 **+137.15% 累计收益**和 **+123.14% 超额收益** (Sharpe 6.94), 比最强基线 Ridge (+91.65% 超额) 高出约 31 个百分点, 并在全部 6 个持有月保持正超额。消融实验表明, Stage 1 预训练、BCE 课程预热、Directional Regression Loss 和 ScaledGatedEncoder 均对性能有明显贡献, 其中训练策略组件的影响大于架构组件。除收益对比外, 本文还通过 Jacobian/SVD、线性探针、特征重要性和极端行情切片分析模型内部行为, 验证模型确实利用了横截面排名、基本面和同业上下文等信号, 而不是仅依赖单股历史趋势。

最后, 本文记录了一次同花顺模拟交易作为端到端压力测试。该模拟最终收益为 -19.40%, 显著弱于离线结果; 但逐日调仓记录显示, 主要问题来自日频信号与盘中人工执行之间的协议差异, 包括非固定买入时点、先卖后买的资金释放约束、弱势市场下的人工择时压力和后期仓位集中。因此, 该结果被解释为**执行层异常案例**, 而不是 CLIME 离线排序能力的直接否定。它进一步说明, alpha

*组员分工: 费维瀚负责项目整体推进、模型设计与实现、实验分析、模拟交易复盘和报告主体撰写; 赵瀚焜、寇之洲参与项目讨论、报告审阅, 并对实验呈现和最终表述提供修改建议。

predictor、risk/scoring、portfolio selection 和 execution 必须作为不同模块分别建模。

1 Introduction

本文以课程大作业中的 A 股日频选股任务为背景，并采用 research-style technical report 的组织方式。为了让报告保持可读性，本文始终围绕一个核心问题展开：**能否学习一个稳定的横截面选股信号，使模型每天把更值得买入的股票排到前面？**在全市场约 5000 只股票中每日选出 top-20 持仓，本质上是一个横截面排序问题：投资决策主要取决于股票之间的相对顺序，而非对单只股票次日收益的精确回归。

需要强调的是，本文研究的是**信号层**而非**完整交易执行层**。我们的离线评估协议使用 top-20 等权日调仓来横向比较不同模型的排序能力；该协议有利于检验模型是否能在 holdout 集上稳定选出相对更优的股票，但并未完整建模手续费、滑点、涨跌停成交约束、换手率控制和多日持有优化。因此，本文报告的离线收益指标应理解为受控协议下的选股信号表现，而不是可直接落地的真实净收益策略。为了检验从模型信号到真实操作之间的差距，本文还记录了一次同花顺模拟交易；该模拟结果较差，但它衡量的是“日频 alpha 信号 + 人工盘中执行”的端到端过程，而不是 CLIME 纯排序信号本身。

我们的核心诊断有两点。第一，股票预测的训练目标需要更贴近最终的排序决策。一方面，学习排序和偏好学习中的经验表明，pairwise supervision 适合学习相对判断 [3, 4, 5, 7, 8]；另一方面，单纯回归损失会对所有数值误差施加近似对称惩罚，却无法区分“方向错误”和“幅度略有偏差”这两类在选股中影响完全不同的错误。第二，只看单只股票自己的历史序列通常不够：A 股中的行业联动、风格轮动和市场状态会同时影响一批股票。若模型完全看不到同业和市场上下文，其上限会受到明显限制。

因此，本文最重要的设计不是简单堆叠更大的 Transformer，而是引入 **peer-aware market context**：对每只股票构造 top-10 相似同业的动态统计量，并与市场上下文一起注入模型。市场信息的注入也需要谨慎处理：简单拼接市场指数或同业信息可能把噪声直接送入 Backbone，而不是形成对个股判断的有约束修正。CLIME 中的 ScaledGatedEncoder 正是为了解决这一点：它只学习一个受门控和幅度约束的表征偏移，让 peer dynamics 作为增量修正进入模型。

基于这些观察，我们提出 **CLIME** (Cross-Modal Injection via Learned Market Encoding)，一种面向股票排序的 Transformer 架构。CLIME 包含三项关键设计：(1) Stage 1 使用 pairwise ranking loss 预训练 Backbone，先学习通用排序先验；(2) Stage 2 通过 BCE 方向预热和 Directional Regression Loss 逐步过渡到次日收益预测；(3) ScaledGatedEncoder 将同业动态和市场上下文以受控加法方式注入表征空间，使市场信息作为增量修正而非直接覆盖个股判断。主实验均使用纯 alpha 分数

($\lambda = 0$) 评估 CLIME 本身的排序能力；风险过滤器仅作为模拟交易中的工程补充。

这种拆分也决定了本文对模拟交易结果的解释方式。若离线排序模型表现较好，但盘中模拟交易收益较差，不能简单得出“模型没有学到信号”的结论。真实收益还受到买入时点、卖出顺序、资金释放、仓位集中、人工择时和市场日内路径的影响。换言之，最终交易收益可以被视为 alpha 信号、组合构造、执行价格和人工干预的叠加结果。第 4 节将展示一个失败的模拟交易案例，并将其作为执行层缺口分析，而不是作为 CLIME 离线排序能力的主要评价指标。

在 holdout 测试集（2025 年 12 月至 2026 年 5 月，共 100 个交易日）上，CLIME 取得**累计收益 +137.15%、超额收益 +123.14%**（Sharpe 6.94），相对最强基线 Ridge（+91.65% 超额）高出约 31 个百分点。消融实验显示，Stage 1 预训练、BCE 课程预热、Directional Regression Loss 和 ScaledGatedEncoder 的移除都会造成明显退化；内部分析进一步表明，模型主要依赖横截面排名、基本面等信号，并形成了紧凑的主导排序方向。

本文的贡献可以概括为四点：第一，将 A 股日频选股明确建模为 top-K 排序任务，并清楚区分选股信号评估与真实交易执行；第二，设计了 peer dynamics 驱动的受控市场信息注入机制，而不是只依赖单股历史序列；第三，通过基线对比、消融实验、Jacobian/SVD、线性探针、特征重要性和极端行情切片，同时评估模型收益、组件贡献和可解释性；第四，结合模拟交易记录分析离线 alpha 信号到真实执行之间的断层，说明一个表现较好的 predictor 仍需要独立的 portfolio construction 和 execution 模块才能成为完整量化系统。

2 Methodology

2.1 Problem Formulation

对于交易日 t ，给定 N_t 只股票的历史特征序列 $\mathbf{x}_i^{(t)} \in \mathbb{R}^{L \times F}$ （ $L = 40$ 个交易日， $F = 67$ 维特征），以及每只股票的同业动态特征 $\mathbf{p}_i^{(t)} \in \mathbb{R}^{24}$ ，模型输出一个标量 alpha 分数 $s_i^{(t)}$ 。该分数不是最终交易指令，而是用于横截面排序的选股信号。每日评估时，我们选取分数最高的 $K = 20$ 只股票构建等权组合，持有一个交易日后卖出，以此衡量模型是否能把次日相对收益更高的股票排在前面。预测标签为次日收益率 $r_i^{(t)} = \frac{\text{close}_i^{(t+1)} - \text{close}_i^{(t)}}{\text{close}_i^{(t)}}$ 。股票池为除 ST 股和北交所外的全部 A 股。

这种表述刻意将系统拆成两层：**预测/排序层**负责产生 alpha 分数，**交易策略层**负责处理交易成本、滑点、换手率、风险预算和实际成交约束。本文主要研究前者；后者只在第 2.5 节和第 4 节作为工程扩展讨论。

2.2 Feature Design

2.2.1 Stock Features

我们使用 67 维个股特征，覆盖收益、量价、技术指标、基本面、资金流向、市场指数、市场宽度、横截面相对排名和位置编码等类别。特征设计参考 Kakushadze 的 101 Formulaic Alphas [17]，目标是系统性覆盖常见量化因子类型，而非手工筛选少数单一因子。所有特征逐日进行横截面标准化，仅使用当日及历史数据；完整特征列表见附录A。

2.2.2 Peer Dynamics

Peer Dynamics 为每只股票提供同业群体的统计画像，这是本文区别于普通单股序列模型的关键输入。直觉上，某只股票的短期表现往往不只由自身历史决定，还受到同业共同上涨/下跌、行业轮动、风格切换和相对强弱变化影响。因此，我们基于行业、业务描述、地区、企业类型和历史收益相关性选取 top-10 相似股票，并聚合同业收益、成交活跃度、技术指标、基本面和个股相对偏差等 24 维特征。

相比直接输入全市场所有股票，Peer Dynamics 是一种低成本、可解释的局部市场上下文：模型看到的是“与当前股票最相关的一组股票正在发生什么”，而不是无结构的全市场噪声。相比只输入市场指数，它又保留了行业 and 同业层面的细粒度差异。相似度权重和聚合细节见附录A。

2.3 Model Architecture

模型整体架构如图2.1所示,采用双流设计:Backbone 处理个股特征序列,ScaledGatedEncoder 处理 peer dynamics 和市场上下文,两者在表征空间通过加法融合。这样的拆分使模型既能保留单股历史序列中的主信号,也能在必要时利用同业和市场状态修正判断。

Figure 1. CLIME Architecture: Market-Aware Additive Injection

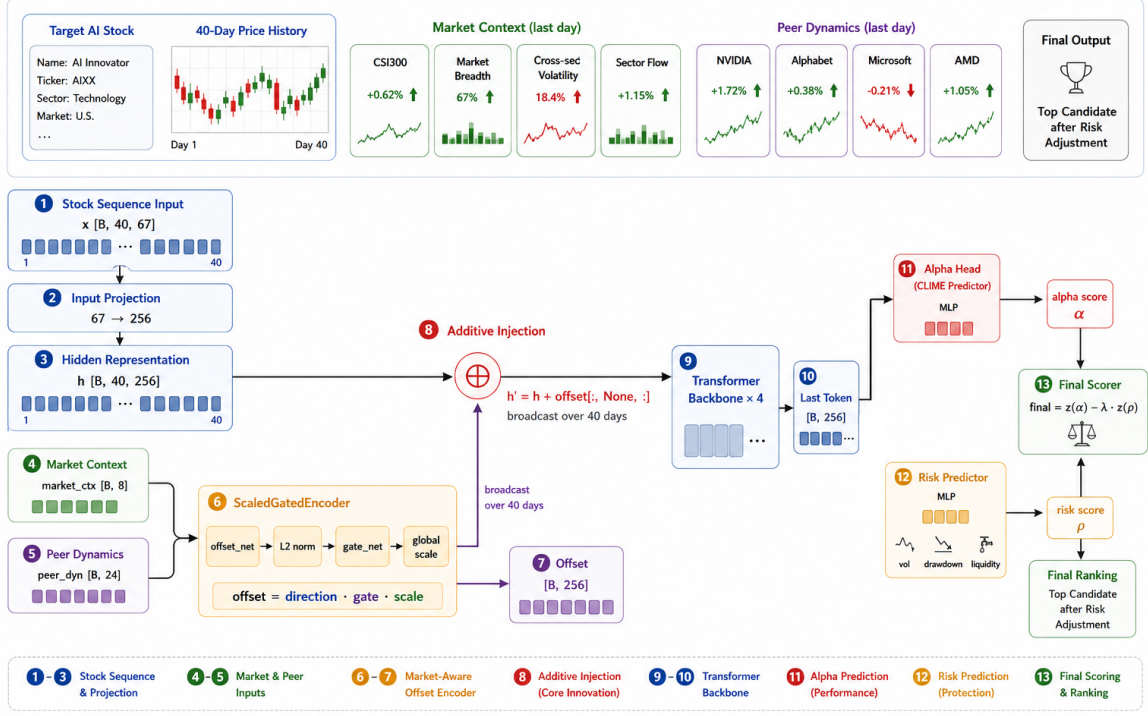


图 2.1: CLIME 模型架构。左侧输入：个股特征序列 $\mathbf{x} \in \mathbb{R}^{B \times 40 \times 67}$ 和同业动态 $\mathbf{p} \in \mathbb{R}^{B \times 24}$ 。中下部：ScaledGatedEncoder 将 peer_dyn 与 market_ctx 拼接，经 offset_net 生成方向向量，由 gate_net 选择性门控和全局 scale 约束后产生 offset。中上部：Backbone 通过 input_proj 将 $\mathbf{x}$ 映射到 256 维表征空间，与 offset 加法融合后经 RoPE 和 4 层 Transformer 处理。右侧：预测头输出标量分数。

2.3.1 Transformer Backbone

Backbone 为标准 Transformer 结构：input_proj ($67 \rightarrow 256$)、旋转位置编码 (RoPE)、4 层 TransformerBlock (Multi-Head Attention, 8 heads, $d = 256$; Feed-Forward hidden=1024; Pre-LN)，最后通过 last-token extraction ($\mathbf{h}[:, -1, :]$) 获取序列表示。Backbone 参数量约 2.3M，采用标准的 Transformer 配置，架构细节在此不做赘述。

2.3.2 ScaledGatedEncoder

ScaledGatedEncoder 是整个架构的核心组件，也是 peer dynamics 进入模型的主要通道。它的目标不是重新生成一个完整预测，而是在 Backbone 已经形成的个股表示上学习一个有约束的市场修正项。该模块由三个子模块构成：

offset_net 将 peer_dyn (24 维) 与 market_ctx (8 维) 拼接后映射为原始偏移向量 $\hat{\mathbf{u}} \in \mathbb{R}^{256}$ ，并进行 L2 归一化： $\mathbf{u} = \hat{\mathbf{u}} / \|\hat{\mathbf{u}}\|$ 。这一设计使 encoder 主要控制修正方向，而不直接控制修正幅度。

gate_net 根据 **market_ctx** 输出门控值 $g \in [0, 1]$ ，为每只股票独立控制市场修正强度。该模块实现**选择性注入**：不同股票可以接收不同程度的市场上下文。

logit_scale 是一个全局可学习标量，经 $\tanh$ 约束后控制 **offset** 幅度。最终 **offset** 合成为：

$$\text{offset} = g \cdot \tanh(s) \cdot \frac{\hat{\mathbf{u}}}{\|\hat{\mathbf{u}}\|} \cdot \sqrt{256} \quad (1)$$

2.3.3 加法注入与设计原则

市场信息通过加法注入 Backbone 的表征空间：

$$\mathbf{h}' = \mathbf{h} + \text{offset} \quad (\text{offset 广播到所有 40 个时间步}) \quad (2)$$

这一加法设计与 FiLM 式乘性调制 ($\gamma \odot \mathbf{h} + \beta$) 形成对比。乘性调制可能直接改变 Backbone 已学到的表征，而加法注入保留原始判断，只学习增量修正。这一思想与 Adapter [15] 和 LoRA [16] 等加性微调方法相近。

三个约束共同限制市场调制的影响范围：**unit-norm** 控制方向，**gate** 控制个股层面的注入强度，**tanh** 约束全局幅度。因此 Backbone 仍是主信号，市场信息只做受控修正。

2.4 Training Pipeline

整体训练流程如图2.2所示，分为两个阶段。

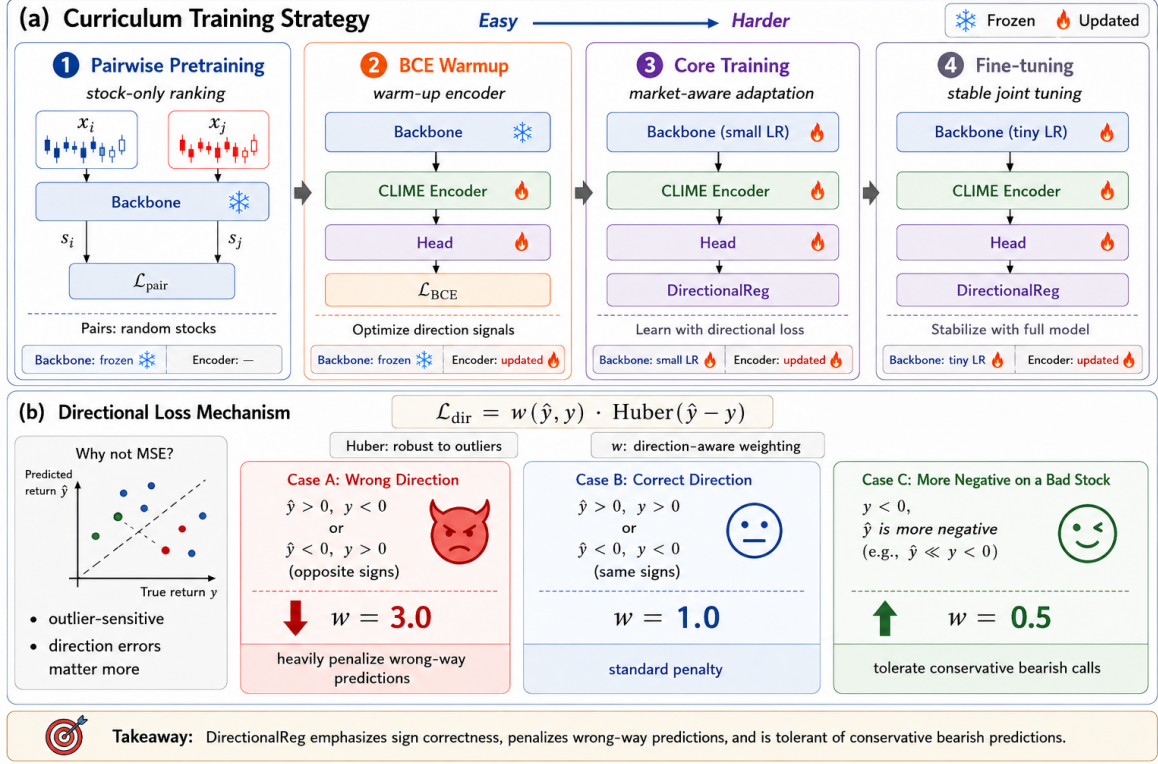


图 2.2: 两阶段训练流程。Stage 1: 使用 Pairwise Ranking Loss 预训练纯 Backbone。Stage 2: 加载 Stage 1 权重, 冻结 Backbone 进行 3 个 epoch 的 BCE 方向预热, 随后解冻 Backbone 以极小学习率 (encoder 的 1/50) 进行 DirectionalReg 核心训练, 最后以更低学习率精调。

2.4.1 Stage 1: Backbone Pretraining

Stage 1 的目标是让 Backbone 学会从 67 维量价特征中提取通用模式, 暂不涉及市场信息。采用 **PairDataset** 构造训练数据: 每日对股票按收益率排序, 分别从 top-10% 和 bottom-10% 中采样并随机配对, 生成约 5000 个 pair 样本。配对约束要求 pair 间的收益率差大于 $\text{margin}=0.002$, 确保 pair 具有足够区分度。

采用 **Pairwise Ranking Loss**:

$$\mathcal{L}_{\text{pair}} = \log(1 + \exp(-y \cdot (s_i - s_j))) \quad (3)$$

其中 $y = +1$ 表示股票 i 的收益率高于股票 j 。该损失直接优化相对排序——训练初期模型无需精确预测“好多少”, 只需学会判断“谁更好”。这是一个比精确值回归更简单的学习任务, 为后续课程学习奠定了基础。Early Stopping 以验证集上的 Top-20 Excess Return 为唯一指标。

2.4.2 Stage 2: Three-Phase Curriculum Training

Stage 2 加载 Stage 1 预训练的 Backbone 权重, 通过三阶段课程训练逐步引入市场调制能力和精细预测能力。各阶段配置见表2.1。

表 2.1: Stage 2 三阶段课程训练配置

Phase	Epochs	Loss	Backbone	Encoder & Head
1 (BCE Warmup)	1-3	BCEWithLogitsLoss	Frozen	10^{-3}
2 (Core)	4-15	DirectionalReg Loss	10^{-5}	5×10^{-4}
3 (Fine-tune)	16-25	DirectionalReg Loss	10^{-6}	$5 \times 10^{-4} / 10^{-5}$ (head)

Phase 1 (BCE 预热): 冻结 Backbone, 仅用涨跌方向分类任务训练随机初始化的 encoder 和 head, 避免回归损失的早期噪声破坏预训练表示。

Phase 2 (核心训练): 切换到 Directional Regression Loss, 解冻 Backbone 并以远小于 encoder 的学习率微调, 使市场编码器逐步适配已有排序表征。

Phase 3 (精调): 所有学习率降低, 系统在最优解附近精细化收敛。

完整训练超参数见附录D。

2.4.3 Directional Regression Loss

Directional Regression Loss 是本工作的核心损失函数设计, 旨在桥接回归的精确性与排序的感知能力。基础层使用 Huber Loss ($\delta = 0.01$) 以对抗极端收益值 (涨停/跌停):

$$H_{0.01}(e) = \begin{cases} 0.5e^2 & \text{if } |e| \leq 0.01 \\ 0.01(|e| - 0.005) & \text{if } |e| > 0.01 \end{cases} \quad (4)$$

上层乘以方向感知的非对称权重:

$$w(\hat{r}, r) = \begin{cases} 3.0 & \text{if } \text{sign}(\hat{r}) \neq \text{sign}(r) \quad \text{【方向错误】} \\ 0.5 & \text{if } \text{sign}(\hat{r}) = \text{sign}(r) < 0 \text{ and } \hat{r} < r \quad \text{【保守悲观】} \\ 1.0 & \text{otherwise} \quad \text{【正常】} \end{cases} \quad (5)$$

$$\mathcal{L} = \frac{1}{N} \sum_{i=1}^N w(\hat{r}_i, r_i) \cdot H_{0.01}(\hat{r}_i - r_i) \quad (6)$$

三个权重的设计逻辑与选股场景精确对应:

- **方向错误 ($\times 3$):** 预测方向与实际收益方向相反, 对 top-20 排序影响最大。
- **保守悲观 ($\times 0.5$):** 方向正确但预测偏低, 该股票通常不会进入 top-20, 因此降低其梯度权重。
- **正常 ($\times 1$):** 方向正确且不满足保守悲观条件, 标准 Huber 惩罚。

与纯排序损失 (pairwise/listwise) 相比, DirectionalReg 保留了收益幅度信息; 与纯回归损失 (MSE) 相比, DirectionalReg 将优化目标重新对齐到了选股的真实需

求——只需要相对顺序正确，不需要精确预测每一个基点。后续消融实验（RQ2）将量化验证这一设计的贡献。

2.5 Risk-Adjusted Scoring

CLIME 模型输出 alpha 分数后，在实际交易中可以叠加一个规则驱动的风险过滤器。该过滤器基于过去 20 日波动率、回撤、振幅和流动性风险构造综合风险分数，最终交易决策分数为：

$$\text{final}_i^{(t)} = z(\alpha_i^{(t)}) - \lambda \cdot z(\text{risk}_i^{(t)}) \quad (7)$$

并在 alpha 分数前 10% 的候选池内进行风险调整排序。该模块无可学习参数，实验部分的所有评估均使用纯 alpha 分数（ $\lambda = 0$ ）；同花顺模拟交易中使用 $\lambda = 0.3$ 作为更保守的执行配置。完整配置见附录G。

3 Experiments

为系统评估 CLIME 的有效性，我们围绕三个核心研究问题组织实验：

- **RQ1（性能对比与稳定性）**：CLIME 在 holdout 测试集上是否显著优于强基线模型？其优势是否在不同的时间跨度和市场环境中保持稳健？
- **RQ2（消融分析）**：两阶段课程训练、Directional Regression Loss、BCE 方向预热、ScaledGatedEncoder——各个设计组件对最终性能的贡献有多大？
- **RQ3（内部分析）**：模型学到了什么？ScaledGatedEncoder 是否真正实现了差异化的市场信息注入？

所有实验均以模型在 holdout 测试集上的**受控 top-20 选股表现**作为最终评价标准。这里的“投资表现”用于横向比较模型排序信号的强弱，而非声称已经覆盖真实交易执行中的全部约束。除非特殊说明，我们以超额收益、Sharpe、最大回撤和胜率作为主要判据，同时在消融实验（RQ2）和内部分析（RQ3）中辅以 RankIC（Rank Information Coefficient）作为统计诊断工具。

重要说明：本章所有实验均使用**纯 alpha 分数**（即 CLIME 模型的原始输出，不经风险调整， $\lambda = 0$ ），以隔离模型本身的排序能力。第2.5节描述的风险过滤器仅在同花顺模拟交易（第4节）中启用。这种解耦设计确保实验评估的是 CLIME 的选股信号本身，而非风险过滤器、换手控制或交易执行规则的附加效果。

3.1 Dataset and Preprocessing

3.1.1 Data Source and Feature Computation

原始数据来源于聚宽（JoinQuant）量化平台，涵盖全部 A 股（剔除 ST 股和北交所股票后约 4000–5000 只）的日频交易数据、基本面指标、资金流向数据和市场指数。数据时间范围为 2015 年 1 月至 2026 年 5 月。基于原始数据，我们计算 67 维量价特征（详见第2节及附录A），涵盖收益类、量价类、技术指标、基本面、资金流向、市场指数、市场宽度和横截面相对排名 8 个类别。

3.1.2 Data Hygiene and Leakage Prevention

金融数据容易因时间自相关和预处理方式引入**前瞻偏差**（look-ahead bias）。为保证评估可信，本文的数据管线遵循三条原则：

1. **时点对齐**：交易日 t 的所有特征只使用 $\leq t$ 的信息，标签为 $t+1$ 日收益。
2. **逐日横截面处理**：缺失值填充、Winsorize 和 z-score 均在同一交易日内独立完成，不跨日期拟合统计量。
3. **时间切分**：训练、验证、holdout 严格按日期划分且互不重叠；holdout 不参与任何模型选择。

此外，我们保留 2026 年 5 月 12 日至 5 月 26 日的 9 个交易日作为纯未来验证集，不参与训练、验证、holdout 评估或任何决策。更详细的数据卫生检查见附录B。

3.1.3 Feature Preprocessing

特征级预处理逐日执行：

1. **缺失值填充**：以当日横截面中位数填充（逐日、逐特征独立处理，不使用跨期信息）。
2. **极端值处理**：以当日横截面的 1% 和 99% 分位数进行 Winsorize 处理（逐日、逐特征独立计算，不跨日期拟合阈值）。
3. **横截面 z-score 标准化**：如上所述，每日独立标准化，仅使用当日横截面均值和标准差。

3.1.4 Train / Validation / Holdout Split

数据集按时间顺序划分为三个互不重叠的部分，如表3.1所示。训练集以 step=10 稀疏采样，验证集和测试集以 step=1 全密度评估。

表 3.1: 数据集划分。所有划分严格按时间排序，互不重叠。

Split	Date Range	Trading Days	Step	Purpose
Train (train_v5)	2016-01-04 – 2025-09-17	~1700	10	Model training
Validation (val_v5)	2025-09-18 – 2025-12-04	50	1	Hyperparameter selection
Holdout (holdout_v5)	2025-12-05 – 2026-05-11	100	1	Final evaluation

验证集用于 Stage 1 和 Stage 2 的早停与超参数选择；holdout 测试集在全部训练完成后仅评估一次。

3.1.5 Stock Universe

股票池为全部 A 股剔除 ST 股和北交所股票；ST 状态按当日可得信息过滤。

3.2 Experimental Settings

3.2.1 Evaluation Protocol and Metrics

评估遵循统一的 **Top-20 等权日调仓** 协议：

1. 在每个交易日 t 收盘后，模型对股票池中所有 N_t 只股票输出预测分数 $s_i^{(t)}$ ；
2. 选取分数最高的 $K = 20$ 只股票，以等权（每只 5%）构建投资组合；
3. 在交易日 $t + 1$ 以收盘价卖出，组合日收益率 $r_{\text{port}}^{(t)} = \frac{1}{20} \sum_{i \in \text{top-20}} r_i^{(t)}$ ，其中 $r_i^{(t)} = \text{close}_i^{(t+1)} / \text{close}_i^{(t)} - 1$ ；
4. 每日重复上述流程，累计收益为日收益的复利累积。

所有实验均**不设交易成本**（单边 0%），以聚焦于模型选股能力本身的比较。组合权重严格等权，不做任何权重优化。

3.2.2 Scope and Differences from Real Trading

我们的实验协议用于评估模型选股信号，因此有意做了若干简化假设：

- 不扣除交易成本和滑点；
- 假设所有 top-20 股票均可按收盘价成交；
- 不显式建模涨跌停、流动性冲击和多日持有策略。

因此，本文收益应被解读为**统一评估协议下的信号收益**，而非可直接提取的策略净收益。这样的协议适合回答“哪个模型在同一 holdout set 上排序更好”，但不能

替代真实交易策略评估。真实交易系统还需要在 alpha 分数之后加入组合构建、交易成本、换手率控制、流动性过滤和成交约束；这些属于交易策略层，而不是本文主要优化的预测层。交易层约束的详细讨论见附录B。

核心指标均以 holdout 测试集上的 top-20 组合表现为准：

- **累计收益 (Cumulative Return):** $\prod_{t=1}^T (1 + r_{\text{port}}^{(t)}) - 1$
- **超额收益 (Excess Return):** $\prod_{t=1}^T (1 + r_{\text{port}}^{(t)}) - \prod_{t=1}^T (1 + r_{\text{market}}^{(t)})$ ，其中 $r_{\text{market}}^{(t)}$ 为当日全部 A 股（除 ST 和北交所）的等权平均收益率。该指标度量模型相对于“闭眼随机买”的超额回报。
- **Sharpe Ratio:** 年化夏普比率， $\text{Sharpe} = \frac{\bar{r}_{\text{excess}}}{\sigma(r_{\text{excess}})} \times \sqrt{250}$ ，其中 $\bar{r}_{\text{excess}}$ 为日均超额收益， $\sigma(r_{\text{excess}})$ 为超额收益的标准差。无风险利率假设为 0。
- **最大回撤 / 日胜率 / 月胜率:** 用于衡量收益路径的稳定性。

3.2.3 Baselines

我们选取 5 类基线模型，覆盖线性模型、树模型和深度时序模型：

- **Ridge:** 使用最后一日 67 维特征的强线性基线 [12]。
- **XGBoost / LightGBM** [19, 20]: 使用最后一日 67 维特征的梯度提升树模型。
- **MLP:** 4 层全连接网络，使用最后一日 67 维特征。
- **GRU:** 2 层循环网络，使用 40 日特征序列。

所有基线使用相同训练、验证和 holdout 划分。树模型以 MSE 回归训练，MLP 和 GRU 使用与 CLIME 一致的数据预处理流程。

3.2.4 Hyperparameters and Implementation

CLIME 的训练分为两个阶段，关键超参数如表3.2所示；完整的超参数配置和硬件环境见附录D。

表 3.2: CLIME 训练关键超参数

Hyperparameter	Stage 1	Stage 2
Optimizer	Adam	Adam
Learning Rate	5×10^{-4}	10^{-5} (backbone) / 5×10^{-4} (encoder)
LR Scheduler	CosineAnnealing (T=40)	CosineAnnealing (T=25)
Batch Size	2048	256
Max Epochs	40	25
Early Stopping Patience	10	8
Weight Decay	10^{-5}	10^{-5}
Gradient Clip	1.0	1.0
Loss Function	Pairwise Ranking	BCE / DirectionalReg

模型使用 PyTorch 实现, 在 NVIDIA A100 (80GB) GPU 上训练。Stage 1 约需 2 小时, Stage 2 约需 1.5 小时。模型总参数量约 2.8M (Backbone 约 2.3M, ScaledGatedEncoder 约 0.5M)。所有报告结果均可由公开代码复现; 从随机初始化重新训练得到的模型在 holdout 集上的核心收益指标与本文使用的 best checkpoint 差异控制在约 5% 以内, 说明结果不是单次随机种子或 checkpoint 选择的偶然产物。

3.3 RQ1: Performance Comparison and Stability

3.3.1 Comparison with Baselines

表3.3展示了 CLIME 与 5 个基线模型在 holdout 测试集 (100 个交易日) 上的对比。市场等权组合同期累计收益为 +14.01%。

表 3.3: RQ1: Holdout 测试集 (2025-12-05 – 2026-05-11, 100 个交易日) 上的性能对比。最优结果以**粗体**标出, 次优结果以下划线标出。RankIC* 列同时报告验证集与 holdout 集的值 (Val / Holdout), 用于诊断统计信号强度与泛化差距。

Model	Cum. Return	Excess	Sharpe	MaxDD	Daily Win	Monthly Win	RankIC*
MLP	-17.17%	-31.18%	-2.05	28.95%	34.0%	1 / 6	0.061 / 0.022
GRU	+13.92%	-0.09%	0.02	12.48%	43.0%	3 / 6	0.070 / 0.047
XGBoost	+93.21%	+79.20%	3.45	12.70%	57.0%	6 / 6	0.053 / 0.017
LightGBM	+105.34%	+91.33%	3.67	14.34%	61.0%	6 / 6	0.047 / 0.014
Ridge	+105.66%	+91.65%	5.91	6.50%	68.0%	5 / 6	0.049 / 0.027
CLIME	+137.15%	+123.14%	6.94	8.03%	65.0%	6 / 6	0.055 / 0.031

*RankIC 格式为 “Val RankIC / Holdout RankIC”。验证集 RankIC 来自训练期间的 val_v5 评估,

holdout RankIC 来自 holdout_v5 最终评估。

CLIME 以 **+123.14% 超额收益** 位居所有模型之首, 比最强基线 Ridge(+91.65%) 高出约 31 个百分点, Sharpe 比率 (6.94) 也最高。MLP 和 GRU 的收益表现明显弱于 Ridge, 说明普通深度模型的额外容量并不会自动转化为 top-20 选股能力。

RankIC 提供了一个重要补充: GRU 在 holdout 上的 RankIC(0.047) 高于 CLIME (0.031), 但实际超额收益仅为 -0.09%。这说明全市场 RankIC 不等价于 top-K 选股能力; 模型可能在中间收益区域排序较好, 却无法准确识别最顶部的 20 只股票。

表 3.4 进一步展示了各模型在 6 个持有月中的月度超额收益分解。

表 3.4: RQ1: 月度超额收益分解。绿色数值表示正超额, 红色数值表示负超额。

Month	MLP	GRU	XGBoost	LightGBM	Ridge	CLIME
2025-12	-7.25%	-1.42%	+14.24%	+16.76%	+13.71%	+14.86%
2026-01	-5.03%	+1.09%	+15.78%	+22.87%	+23.15%	+34.51%
2026-02	-3.30%	-1.74%	+10.86%	+10.06%	+5.31%	+3.30%
2026-03	-9.40%	+3.49%	+1.41%	+0.82%	+15.37%	+10.87%
2026-04	-6.33%	-1.40%	+9.36%	+6.04%	+6.83%	+13.73%
2026-05	+0.16%	+0.04%	+4.77%	+6.59%	-1.66%	+3.01%
Positive Months	1 / 6	3 / 6	6 / 6	6 / 6	5 / 6	6 / 6

CLIME 在全部 6 个持有月均取得正超额, 并保持最高累计超额。XGBoost 和 LightGBM 同样达到 6/6 月度胜率, 但累计超额低于 CLIME。

3.3.2 Stability across Time and Market Regimes

上述月度分析仅覆盖 holdout 期间的 6 个月。要回答“CLIME 的表现是否为运气”这一问题, 需要在更长的时间跨度和更多样化的市场环境中进行检验。我们选取了 A 股市场 2018 年至 2024 年间具有代表性的 9 段极端行情——5 段熊市和 4 段牛市——使用完全相同的 CLIME 模型 (无针对特定行情的任何调整) 进行回测:

- **2018 全年 (熊市):** 中美贸易战导致 A 股全年单边下跌, 上证指数跌幅超 24%, 全市场等权下跌约 15%。
- **2020 年 2 月 (熊市):** 新冠疫情爆发引发全球恐慌, 春节后首个交易日上证暴跌 7.72%, 为近年来最大单日跌幅。
- **2022 Q1-Q2 (熊市):** 上海封城叠加美联储暴力加息, 上证指数一度跌破 3000 点, 市场等权累计跌幅接近 20%。
- **2024 年 2 月 (熊市):** 微盘股流动性危机, 雪球产品集中敲入引发中小市值股票恐慌性抛售。

- **2026 年 5 月 15 日（熊市）**：近期市场单日急跌，市场等权单日下跌 1.24%。
- **2019 Q1（牛市）**：春季躁动行情，政策宽松驱动 A 股全面反弹，全市场等权上涨超 27%。
- **2020 Q2–Q3（牛市）**：后疫情复苏行情，全球流动性泛滥推动 A 股持续上行，市场等权上涨超 23%。
- **2020–2021（牛市）**：蓝筹股泡沫期，核心资产估值急剧膨胀，白酒、新能源等赛道股领涨。
- **2024 Q3–Q4（牛市）**：政策组合拳（降印花税、汇金增持、地产救助）触发政策牛市，但分化剧烈——全市场等权反而下跌 5.60%。

表 3.5: CLIME 在 9 段历史极端行情中的表现。所有回测使用完全相同的模型权重，无针对特定行情的调整。

Regime	Description	Port. Cum.	Mkt. Cum.	Excess	Daily >0
Bear	2018 Trade War	+49.60%	+1.65%	+47.95%	–
	2020-02 COVID Crash	+9.44%	–	–	100%
	2022 Q1–Q2 Lockdown	+6.61%	–19.64%	+26.25%	–
	2024-02 Micro-cap	+6.86%	+2.05%	+4.81%	–
	2026-05-15 Sell-off	+1.63%	–1.24%	+2.87%	–
Bull	2019 Q1 Spring	+30.74%	+27.63%	+3.11%	57%
	2020 Q2–Q3 Recovery	+60.53%	+23.08%	+37.45%	82%
	2020–2021 Blue-chip	+56.83%	+16.29%	+40.54%	87%
	2024 Q3–Q4 Policy	+107.38%	–5.60%	+112.98%	100%

CLIME 在 9 段历史极端行情中均取得正超额收益，说明其表现并不只依赖 hold-out 期间的单一市场环境。其中 2024 Q3–Q4 政策行情最为突出：全市场等权收益为 –5.60%，CLIME 超额收益为 +112.98%。

综合来看，CLIME 在收益和稳定性上均优于基线：holdout 超额收益最高，6/6 月和 9 段历史极端行情均保持正超额。MLP 和 GRU 的弱表现也支持了本文的核心观察：在高噪声股票排序任务中，训练范式可能比单纯增加模型复杂度更重要。

3.4 RQ2: Ablation Studies

RQ2 通过四项消融实验量化核心组件的边际贡献。每个变体仅改变一个组件，其余配置与完整 CLIME 一致：

- **T1_MSE**: Directional Regression Loss 替换为标准 Huber Loss。
- **T2_NoCur**: 跳过 BCE 方向预热，直接训练 Stage 2。
- **T3_NoS1**: 跳过 Stage 1 pairwise 预训练。
- **E1_NoEnc**: 移除 ScaledGatedEncoder，仅保留纯 Transformer Backbone。

表 3.6: RQ2: 消融实验结果。 ΔExcess 表示相对于完整 CLIME 的超额收益变化。Val RankIC* 为训练期间验证集上的最佳 RankIC 值。

Variant	Excess	ΔExcess	Sharpe	MaxDD	Daily Win	Monthly Win	Val RankIC*
CLIME (Baseline)	+123.14%	–	6.94	8.03%	65.0%	6 / 6	0.0284
T1_MSE	+65.81%	–57.33 pp	4.88	12.12%	64.0%	6 / 6	0.0360
T2_NoCur	–5.19%	–128.33 pp	0.91	13.15%	46.0%	3 / 6	0.0092 [†]
T3_NoS1	–27.21%	–150.35 pp	–1.14	25.16%	42.0%	1 / 6	0.0186
E1_NoEnc	+49.25%	–73.89 pp	3.60	16.44%	62.0%	5 / 6	0.0137 [†]

* 训练期间在验证集 (val_v5) 上记录的 RankIC 最佳值，用于诊断训练质量和排序信号强度，与 holdout 投资指标互补。[†]T2_NoCur 和 E1_NoEnc 在首个 epoch 后 RankIC 迅速崩溃至 0.0 (参见正文分析)。

四个消融变体均明显退化,影响程度为:T3_NoS1(–150pp) > T2_NoCur(–128pp) > E1_NoEnc(–74pp) > T1_MSE(–57pp)。其中，去掉 Stage 1 预训练和 BCE 预热的破坏力大于去掉市场编码器，说明训练范式是 CLIME 性能的主要来源之一。

Val RankIC 提供了补充视角:T1_MSE 的 Val RankIC(0.0360)高于完整 CLIME (0.0284)，但实际超额收益低 57pp。这说明更高的全局排序相关性不一定带来更好的 top-20 组合收益，也支持 DirectionalReg 将优化重心从幅度拟合转向方向和排序质量的设计。

3.5 RQ3: Internal Analysis

RQ3 从输入空间、表征空间和特征空间分析 CLIME 内部是否学到了稳定的排序结构，而不只依赖终端收益评估。

3.5.1 Experiment 1: Jacobian Analysis —How Many Directions Does the Model Use?

我们在 holdout 数据上对约 25,000 个样本计算模型输出关于 67 维输入特征的 Jacobian，并对其进行 SVD 分解，以观察模型预测主要依赖多少个局部敏感方向。




图 3.1: Jacobian 奇异值谱。左: 对数尺度下的奇异值衰减。右: 主导方向 (Direction 1) 中 top-15 特征的载荷。

结果: Jacobian 的有效秩为 1——第一个奇异值占据了 95% 以上的方差，其余 66 个奇异值几乎为零。这说明在局部敏感性意义下，模型预测主要沿着一个**复合特征方向**变化：67 维输入对最终分数的边际影响被压缩到一个主导方向上。需要注意的是，Jacobian 只能描述局部线性响应，不能单独证明模型只依赖一个全局因子；它更合理的解读是，模型在高噪声特征中形成了一个占主导地位的排序方向。

主导方向的高载荷特征横跨横截面排名、市场指数和资金流向，说明该方向不是单一因子，而是多个异质信号的组合。有效秩 = 1 不能单独证明模型只依赖一个全局因子，但说明其局部敏感性高度集中，可能有助于抑制噪声。

3.5.2 Experiment 2: Linear Probe —Can a Linear Model Read Out the Prediction?

我们在 Backbone 最后一层表征上训练线性分类器，并用 67 维原始特征线性回归模型输出分数，以区分线性可读信号和非线性残差的贡献。

表 3.7: 线性探测与线性/非线性分解结果。

Metric	Value
Linear Probe AUC (good vs bad stock)	0.806
Linear Probe Spearman ρ	0.415
Linear Decomposition R^2	0.206
Nonlinear fraction of score variance	79.4%
Spearman ρ (full_score, linear_score)	0.003
Top-20 by full model score (mean daily excess)	+2.15%
Top-20 by linear component only	+2.12%
Top-20 by nonlinear residual only	+0.15%

线性探针 AUC 达到 0.806，说明表征空间中存在较清晰的”好股票方向”。同时，

线性分解的 R^2 仅为 0.206，全模型分数与线性分量 Spearman 相关几乎为 0，说明非线性变换显著改变了排序结构。值得注意的是，线性分量 top-20 日均超额 (+2.12%) 接近全模型 (+2.15%)，而非线性残差单独选股仅为 +0.15%。这表明最强选股信号本身是线性可读的，非线性部分更多是在重排和稳定这些信号，而非提供独立 alpha。

3.5.3 Experiment 3: Feature Group Importance —Which Features Matter?

我们在 holdout 数据上逐组置零特征，观察 top-20 组合超额收益变化，以衡量不同信号源的重要性。

表 3.8: 特征组重要性分析。 ΔExcess 为置零该组后超额收益相对于 baseline (+30.67%) 的变化，正值表示该组被移除后超额下降（该组有用），负值表示该组被移除后超额上升（该组有害）。

Feature Group	#Features	ΔExcess	Impact
Cross-Sectional	10	+34.66 pp	Critical
Fundamental	7	+34.21 pp	Critical
Returns	8	+6.97 pp	Moderate
Industry	6	+6.91 pp	Moderate
Technical	8	+4.74 pp	Moderate
MoneyFlow	6	+4.33 pp	Moderate
Price/Volume	6	+2.86 pp	Low
Market Breadth	6	+0.99 pp	Low
Peer Dynamics	24	+0.00 pp	None
Market Index	9	-1.04 pp	Harmful

结果显示，横截面排名和基本面是最重要的两类信号；市场指数作为 Backbone 直接输入反而带来负贡献，支持我们将市场信息独立注入而非简单拼接的设计。Peer Dynamics 在 Backbone 特征空间中贡献为 0.00pp，但这并不等于 peer 信息无用：E1_NoEnc 同时切断 peer dynamics 和 market context 的注入路径，并导致 -74pp 退化，因此 encoder 内部不同输入源的贡献仍需进一步分离。

3.5.4 Experiment 4: Representation Quality —Does Separation Improve Across Layers?

最后，我们将各层 last-token 表征用 PCA 投影到二维空间，观察 top-20% 与 bottom-20% 收益股票的分离程度。




图 3.2: 各层表征的 PCA 可视化。蓝色为 top-20% 收益股票，红色为 bottom-20% 收益股票。从 Block 0 到 Block 3，两类股票在表征空间中的分离程度明显增加。

从 Block 0 到 Block 3，两类股票的 PCA 分布逐步分离，说明 Transformer 层确实在逐步形成更具排序判别力的表征。

3.5.5 Summary of RQ3

RQ3 的核心结论是：CLIME 学到的信号具有可解释结构。模型在局部敏感性上形成紧凑主导方向，表征空间中存在可线性读出的好股票方向，主要信号来自横截面排名和基本面，而市场信息更适合通过独立 encoder 注入。整体来看，CLIME 的表现更可能来自训练目标、架构约束与任务结构之间的共同匹配。

4 Trading Simulation

4.1 模拟交易设置

前文的离线实验评估的是 CLIME 的日频横截面排序能力：在第 t 天，根据历史特征预测下一交易日哪些股票具有更高收益。相比之下，同花顺模拟交易额外引入了一个真实执行层，包括盘中手动下单、旧仓卖出后的资金释放、新仓买入时点、成交价格 and 仓位集中度等因素。因此，本节更适合作为“模型信号到真实执行”的压力测试，而不是 CLIME 纯 alpha 排序能力的独立检验。

模拟交易中使用的交易分数为 CLIME alpha 分数叠加风险过滤器：

$$s_i = z(\alpha_i) - 0.3 \cdot z(\text{risk}_i), \quad (8)$$

其中 α_i 为 CLIME 输出的股票排序分数， risk_i 为第 2.5 节定义的历史波动风险分数。该设置与第 3 节的主要离线实验不同：离线实验中设置 $\lambda = 0$ ，目的是隔离 CLIME 本身的排序能力；而模拟交易中启用风险过滤器，是为了在实际买入前加入一个工程化的风险控制补充。

日期	操作	股票名称	数量	价格
2026-06-11	买入	新易盛	1500.00股	570.02元
	卖出	腾景科技	702.00股	191.97元
	卖出	完美世界	53200.00股	13.65元
2026-06-10	买入	完美世界	53200.00股	14.33元
	卖出	中微公司	353.00股	295.58元
	卖出	寒武纪	500.00股	1314.00元
2026-06-09	买入	腾景科技	500.00股	208.41元
	卖出	北方华创	100.00股	603.58元

(a) 后期调仓记录

日期	操作	股票名称	数量	价格
2026-06-08	买入	寒武纪	300.00股	1242.00元
	卖出	青木科技	200.00股	38.79元
	卖出	江苏雷利	500.00股	34.36元
2026-06-05	卖出	国瓷材料	800.00股	58.08元
	卖出	青木科技	1000.00股	38.84元
	卖出	江苏雷利	1000.00股	34.41元
2026-06-05	卖出	科华数据	1200.00股	37.65元
	卖出	江顺科技	400.00股	116.80元

(b) 中期调仓记录

图 4.1: 同花顺模拟交易记录示例。完整截图识别结果另存为交易记录整理文件。

4.2 账户结果

同花顺模拟交易的最终结果如表 4.1 所示。最终收益为 -19.40% ，排名为 119/119。这一结果显著弱于离线 holdout 上的模型表现，但它不应被直接解释为 CLIME 排序信号失效。根据交易过程记录，账户在模拟中期仍约为 -4.82% ，最终的大幅回撤主要发生在后期少数集中持仓和不利盘中成交之后。因此，本节将该结果视为一个执

行协议偏离后的异常案例：它说明日频 alpha 信号若缺少固定调仓协议和自动执行约束，可能被盘中执行误差显著放大。

表 4.1: 同花顺模拟交易账户结果

指标	数值
总收益率	−19.40%
月收益率	−19.40%
选股成功率	21.90%
最终排行榜名次	119/119
模拟中期账户收益	约 −4.82%

4.3 逐日调仓记录

表 4.2整理了截图中可识别的逐日调仓记录。可以看到，前期操作更接近分散持仓和日频换仓；后期则逐渐出现更强的人工择时和集中持仓，这也是最终收益被少数交易主导的重要原因。

表 4.2: 模拟交易逐日调仓记录（根据同花顺截图识别）

日期	买入 / 加仓	卖出 / 减仓	执行特征
06-01	青龙管业 12.76/12.61, 中国银行 5.88, 国检集团 7.00, 韩建河山 6.06, 华电能源 9.69, 粤电力 A 9.76, 阳光股份 4.89, 欧晶科技 26.03, 新亚电子 25.90	无可见卖出记录	初始建仓，整体较分散，但成交集中在 11:00 后，已不是严格开盘建仓。
06-02	招商银行 38.83, 浙大网新 8.20, 红星发展 38.49, 胜利精密 3.75	欧晶科技 26.08, 中国银行 6.01, 华电能源 9.54, 韩建河山 6.06, 国检集团 7.00, 阳光股份 4.93	先释放部分旧仓资金，再买入新组合；整体仍接近日频调仓。
06-03	光迅科技 227.80, 寒武纪 1406.42, 裕太微-U 249.00, 宝鹰股份 4.76, 伊利股份 26.63, 中国铁建 6.39, 美的集团 82.22, 宁德时代 428.00, 荣旗科技 83.17, 海航控股 1.51, 中远海控 14.66	粤电力 A 8.65, 青龙管业 11.74, 招商银行 38.55, 红星发展 42.72, 浙大网新 7.90, 新亚电子 24.50, 胜利精密 3.57	大规模换仓；卖出多在早盘完成，买入分布在 10:00 后至下午，存在明显盘中价格路径影响。

日期	买入 / 加仓	卖出 / 减仓	执行特征
06-04	中微公司 283.99	伊利股份 26.57, 光迅科技 223.49, 裕太微-U 230.00, 宝鹰股份 4.69, 美的集团 82.30, 海航控股 1.49, 中远海控 14.64, 中国铁建 6.31	降低前一日持仓, 买入集中度开始上升。
06-05	青木科技 41.02, 腾讯科技 246.20, 江苏雷利 31.61, 江顺科技 110.24, 国瓷材料 65.62, 北方华创 617.62, 寒武纪 1379.99, 科华数据 39.04	荣旗科技 83.00, 寒武纪 1377.00	当日买入集中在 10:00 后, 部分高波动股票盘中买卖, 执行误差开始变大。
06-08	寒武纪 1242.00	青木科技 38.79/38.84, 江苏雷利 34.36/34.41, 国瓷材料 58.08, 科华数据 37.65, 江顺科技 116.80	先卖出旧组合再买入新标的; 多笔卖出发生在 10:00 后和下午, 资金释放与新仓买入存在时滞。
06-10	完美世界 14.33, 腾讯科技 208.41	中微公司 295.58, 寒武纪 1314.00, 北方华创 603.58	持仓开始明显集中, 组合不再严格对应固定 top-K 分散协议。
06-11	新易盛 570.02	腾讯科技 191.97, 完美世界 13.65	后期集中持仓交易; 新易盛后续浮亏较大, 是最终回撤的重要来源。

4.4 盈亏来源分析

表 4.3列出了若干可配对的代表性盈亏来源。该表只根据截图中的成交价和持仓现价估算, 不包含手续费、滑点、印花税和现金占用影响。从结果看, 模拟交易并非所有模型相关标的都失败: 红星发展、江苏雷利、江顺科技、寒武纪等交易均产生正收益; 真正主导最终回撤的是少数后期高波动、集中持仓和不利成交价格。

表 4.3: 代表性盈亏来源（按截图成交价估算）

股票	区间 / 状态	买入或成本价	卖出或标记价	收益率	解释
新易盛	最终持仓	570.20	506.46	-11.18%	后期集中持仓浮亏，是最终回撤的主要来源之一
完美世界	06-10 至 06-11	14.33	13.65	-4.75%	后期集中交易亏损
国瓷材料	06-05 至 06-08	65.62	58.08	-11.49%	买入后出现较大回撤
粤电力 A	06-01 至 06-03	9.76	8.65	-11.37%	前期大额亏损来源
青木科技	06-05 至 06-08	41.02	38.83	-5.33%	执行路径不利
红星发展	06-02 至 06-03	38.49	42.72	+10.99%	明显盈利交易
江苏雷利	06-05 至 06-08	31.61	34.39	+8.79%	明显盈利交易
江顺科技	06-05 至 06-08	110.24	116.80	+5.95%	盈利交易
寒武纪	06-08 至 06-10	1242.00	1314.00	+5.80%	高波动标的中的盈利交易

4.5 执行偏差与结果解释

本次模拟交易最重要的经验是：**模型预测任务、组合选择任务和交易执行任务不能混为一谈**。CLIME 在训练和验证阶段优化的是下一交易日的横截面收益排序；也就是说，它回答的问题是：在给定第 t 日以前的信息后，哪些股票在第 $t+1$ 日更可能排在收益靠前的位置。这个任务天然适合用 RankIC、top- K 收益、分组收益等指标评价，但它并不直接回答盘中买点、卖点、成交价、资金释放顺序、换手成本、仓位集中度和人工执行纪律等问题。因此，模拟交易中的最终收益并不是模型分数的单一函数，而是多个模块共同作用后的结果。

为了更清楚地区分这些因素，可以将真实模拟收益理解为如下几类影响的叠加：

$$R_{\text{realized}} = R_{\text{alpha}} + R_{\text{portfolio}} + R_{\text{execution}} + R_{\text{discretion}}, \quad (9)$$

其中 R_{alpha} 来自 CLIME 对股票相对收益强弱的排序能力， $R_{\text{portfolio}}$ 来自 scorer 和 selector 如何把排序分数转化为持仓组合， $R_{\text{execution}}$ 来自具体成交时点、成交价格 and 资金约束， $R_{\text{discretion}}$ 则来自手动执行中的临时判断和策略一致性偏移。离线实验主要隔离评估 R_{alpha} ，而同花顺模拟交易同时混入了后面三项。因此，当模拟交易出现 -19.40% 时，更合理的解释不是“CLIME 没有学到 alpha”，而是“alpha 信号在未被严格执行协议保护的情况下，被组合构造和盘中执行误差显著稀释甚至反转”。

表 4.4 进一步总结了本次模拟交易中的主要偏差来源。可以看到，最终收益较差并不是由单一原因造成的，而是多个现实交易约束共同叠加后的结果。尤其是对于一个日频 ranking 模型而言，只要执行价格不再接近统一调仓价格，离线排序优势就可能被日内价格路径显著削弱。

表 4.4: 模拟交易结果的执行偏差归因框架

偏差来源	具体表现	对结果的影响	对模型评价的含义
日频预测与盘中执行不一致	模型预测下一交易日收益排序, 但实际买入常发生在 10:00 后或下午	若标的早盘已上涨, 实际买入价会消耗原本的日频 alpha	该误差主要属于执行层, 而不是预测器本身
先卖后买的资金释放约束	需要先卖出旧仓才能买入新推荐股票, 旧仓低开时容易延迟换仓	等待旧仓反弹会错过新仓更优价格, 形成路径依赖	离线 top- K 评估默认同步调仓, 未覆盖该约束
弱势市场中的人工择时压力	连续下跌时更容易等待反弹、推迟卖出或临时改变买入节奏	执行逐渐偏离固定、机械、可复现的交易协议	该部分属于人工决策项, 会污染模型信号评价
后期仓位集中	后期少数股票持仓权重明显上升, 例如新易盛、完美世界	个股波动被放大, 最终收益被少数交易主导	结果不再等价于分散 top- K 排序策略
缺少自动化执行模块	没有固定开盘执行、成交价控制、滑点建模和仓位上限	真实收益同时混入成交价格、人工判断和市场路径	暴露的是完整交易系统缺口, 而非单纯阿尔法模型缺口

第一层偏差来自**预测标签与成交价格之间的时间尺度不一致**。CLIME 的标签是下一交易日收益排序, 本质上接近一个日频 close-to-next-day 的相对比较问题; 但模拟交易中的盈亏由真实成交价决定。如果模型在前一晚给出某只股票的高分, 理想执行应当在固定调仓时点迅速买入, 至少要保证不同股票之间的执行价格具有可比性。但实际操作中, 许多买入并没有发生在 9:30 附近, 而是发生在 10:00 之后甚至下午。对于日内波动较大的股票, 如果其早盘已经上涨, 那么晚买入会显著抬高成本, 原本属于模型预测的日频 alpha 会被盘中价格变化吃掉。反过来, 如果股票高开低走, 模型可能在日频收益上仍然判断正确, 但由于买在盘中高位, 真实账户仍会亏损。也就是说, CLIME 预测的是“哪只股票下一天更值得买”, 而模拟交易还额外要求回答“以什么价格买到它”, 后者并不在模型训练目标之内。

第二层偏差来自**先卖后买的资金释放约束**。离线回测通常默认可以在统一调仓时点将旧组合切换到新组合, 或者至少默认卖出和买入可以近似同步完成。但在真实模拟账户中, 买入新推荐股票之前往往必须先卖出旧持仓释放资金。弱势市场会显著放大这个约束: 旧持仓低开时, 立即卖出会锁定亏损; 等待旧持仓反弹, 则可能错过新推荐股票的早盘买点。这就形成了一个路径依赖问题: 为了避免在旧仓低点卖出, 执行会被迫延后; 而一旦执行延后, 原本想买入的新股票可能已经上涨, 导致买入价格恶化。前面调仓表中多笔买入分布在 10:00 后和下午, 正说明最终收益已经不只是模型排序结果, 而是被“旧仓卖出时点”和“新仓买入时点”共同决定。

第三层偏差来自**弱势市场下的人工执行压力**。从交易过程看, 模拟期间整体市

市场环境并不友好，连续下跌会使执行者面临更强的心理压力：一方面，旧仓下跌时不愿在低位卖出；另一方面，新推荐股票若早盘上涨，又容易出现追高买入或放弃买入之间的摇摆。于是，交易行为会逐渐偏离一个固定、机械、可复现的量化协议，转而混入等待反弹、人工择时、风险厌恶和短期情绪等因素。这一点也解释了为什么账户中期仍约为 -4.82% ，但后期快速扩大到 -19.40% ：最终回撤并不是平滑地来自所有交易，而是在市场压力下被少数高波动交易和不利成交路径集中放大。

第四层偏差来自**仓位集中度与策略一致性偏移**。离线 ranking 评估通常使用 top- K 分散组合来检验排序信号，核心思想是用一组高分股票的平均表现抵消个股噪声。但后期模拟交易逐渐转向少数股票的集中持仓，例如新易盛、完美世界等交易对最终账户收益产生了过高影响。这种集中持仓会把 ranking 模型的横截面优势转化为个股短期波动暴露：如果集中标的方向正确，收益可能迅速改善；但如果买入时点不利或个股当天波动反向，亏损也会被快速放大。表 4.3 中，红星发展、江苏雷利、江顺科技、寒武纪等交易仍然产生正收益，说明并不是所有模型相关交易都失败；真正主导最终回撤的是新易盛、完美世界、国瓷材料、粤电力 A 等少数亏损较大的交易。这说明最终结果更接近“执行层和仓位层对收益分布的重加权”，而不是纯粹的 alpha 排序失败。

第五层偏差来自**模拟交易协议与离线验证协议不完全一致**。离线验证阶段的核心是可复现：固定样本、固定标签、固定 top- K 规则、固定评价指标，因此不同模型之间可以横向比较。而模拟交易阶段如果没有严格规定“每天何时卖出、何时买入、是否等权、最大单票仓位、是否允许人工覆盖模型推荐、是否允许后期集中持仓”等细节，那么最终结果就会同时反映模型、策略、人工判断和市场运气。这个问题在真实量化系统中通常由 execution engine 和 portfolio optimizer 解决，而不是由 predictor 本身解决。因此，本次交易模拟更像是一次端到端系统压力测试：它暴露的是从研究型 alpha 模型走向可交易系统时，哪些工程约束还没有被完全固定。

在这个意义上， -19.40% 可以被解释为一个**执行协议偏离后的异常结果**，而不是 CLIME 离线排序能力的正常外推。更准确地说，它说明：如果没有固定调仓时点、自动化执行、仓位上限、换手约束、交易成本建模、T+1 约束处理、盘中成交价格控制和风险暴露管理，那么即使离线模型具有较好的横截面排序能力，最终模拟收益也可能被人工执行误差、市场路径和集中持仓显著削弱。该结果本身虽然非常差，但它是一个有价值的 failure case，因为它把离线预测和真实交易之间缺失的中间层清楚暴露出来。

这也反过来支持了本文前面对系统架构的拆分：predictor 负责输出可排序的 alpha 信号；risk predictor 负责估计历史波动和下行风险；scorer 负责根据收益偏好和风险偏好生成最终分数；selector 负责构造组合；execution 则负责把组合以固定、可复现、低滑点的方式落地。本次模拟交易中，问题最明显地出现在 selector 之后的 execution 层，而不是 predictor 本身。因此，本文没有把模拟交易结果作为 CLIME 模型能力的主要评价指标，而是将其作为对完整量化交易系统的反思：一个 solid 的

预测模型只是系统的一部分，只有当交易协议也被形式化之后，离线 ranking 优势才可能稳定转化为真实收益。

4.6 小结

同花顺模拟交易给出的结论是：日频 alpha 模型本身并不等价于完整量化交易系统。CLIME 可以提供横截面排序信号，但若要稳定转化为真实收益，还需要独立的 portfolio construction 和 execution 模块，包括固定调仓时间、仓位上限、换手约束、交易成本建模、自动化下单和盘中成交价格控制。本次 -19.40% 的结果虽然非常差，但它的价值在于暴露了离线模型到真实交易之间的执行层缺口，也进一步说明本文将“预测排序”和“交易执行”拆分讨论是必要的。

5 Discussion & Reflection

5.1 Design Principles Revisited

回顾从 V5 到 V9CA_AB 的迭代，有三条经验最值得保留：

1. **受控增量修正比强调制更稳定：**在本任务中， $h' = h + \text{offset}$ 比 FiLM 式乘性调制更可靠；训练策略上，pairwise $\rightarrow$ BCE $\rightarrow$ DirectionalReg 的渐进课程也优于一步到位。
2. **训练信号比模型容量更关键：**MLP 和 GRU 的弱表现，以及 T3_NoS1/T2_NoCur 的明显退化，都说明高噪声金融数据中不能只依赖更复杂的模型。
3. **逐项验证是必要工程纪律：**V11 一次堆叠三项未经验证的改动后明显退化，说明本类项目中每个改动都需要独立验证。

5.2 What We Would Do Differently

在项目时间约束下，仍有几个方向未能充分探索：

- **Gate 机制需要系统性验证：**E1_NoEnc 说明 encoder 整体重要，但目前还无法将收益退化干净归因到 gate、peer dynamics 或 market context 中的某一项。后续应按行业/市值分组统计 gate 值，并做更细粒度消融。
- **执行层仍需建模：**第 4 节的同花顺模拟交易显示，即使离线排序信号较强，真实模拟收益仍可能被盘中执行时点、成交价格、先卖后买的资金释放约束、仓位集中和人工择时显著削弱。尤其是本文离线协议采用每日 top-20 调仓，本身会带来较高换手；如果没有明确的换手惩罚、成交价假设和自动执行规则，交易层误差会直接侵蚀信号收益。后续应将 predictor、scorer/selector 和 execution 拆成独立模块，并固定调仓时点、仓位上限、换手约束和自动化下单协议。
- **新闻文本数据未能利用：**本次作业提供了 2019 年以来的每日新闻快讯数据。考虑到文本多模态处理的技术复杂度和项目时间约束，我们选择了聚焦于结构化量价特征——但新闻中的政策信号、行业事件等信息显然是 peer dynamics 和市场环境的重要补充。

5.3 Conclusion

本文提出了 CLIME，一种面向 A 股日频 top-K 选股的 Transformer 排序模型。实验结果显示，两阶段训练、方向感知损失和受控市场信息注入共同提升了 holdout 收益和稳定性；内部分析也表明模型学到的并非纯噪声，而是以横截面排名、基本面和同业上下文为主的紧凑排序信号。

本工作仍有明确边界。第一，超参数搜索不充分，学习率、层数、head 数等配置尚未系统扫描。第二，特征工程规模有限，67 维特征虽覆盖主要因子类别，但尚未做大规模特征筛选。第三，CLIME 仍是预测模型，不是完整交易系统；交易成本、流动性、涨跌停和执行时点都会削弱可实现收益。第四，同花顺模拟交易最终收益为 -19.40%，这暴露了离线 alpha 模型到真实交易之间的执行层缺口：日频排序信号若缺少固定调仓协议、自动化执行和仓位约束，可能被盘中价格路径和人工干预显著稀释。

更坦诚地说，CLIME 当前解决的是一个相对“干净”的问题：在每天收盘后的信息集合下，预测下一交易日哪些股票更可能获得相对更好的收益。这个设定适合课程任务中的横向模型比较，也适合检验模型是否学到了可排序的 alpha 信号；但它并不直接解决真实操作中最麻烦的部分。实际交易中，首先要卖出旧仓才能买入新仓，卖出时点和买入时点并不天然同步；同时，A 股日内 K 线波动明显，早盘上涨、午后回落或高开低走都会使“预测对了方向”和“账户赚到钱”之间出现差距。再加上 top-20 日调仓本身带来较高换手，短短约十个交易日的模拟比赛窗口又容易受到阶段性大盘环境影响，因此一次短期模拟交易的收益路径可能显著偏离 100 个交易日 holdout 上的平均信号表现。

这并不是说模拟交易结果可以被忽略。相反，它指出了本文最现实的不足：我们证明了模型在受控协议下能给出较强的次日排序信号，但还没有把这个信号完整转化为一个低换手、可成交、可复现的交易系统。若后续继续推进，最重要的改进不是再把 predictor 堆得更大，而是在模型分数之后加入换手惩罚、持仓惯性、日内成交规则、T+1 约束、交易成本估计和风险预算。只有这些模块被形式化之后，离线 top-20 收益才更可能稳定转化为真实模拟收益。

因此，CLIME 在本课程项目设定下是一个表现较强的次日排序模型，但若要走向实用量化系统，还需要在特征筛选、超参数搜索、组合构造和交易执行层上继续工程化。更准确地说，本文完成的是 alpha predictor 和信号解释，而不是完整自动交易系统；模拟交易中的失败案例恰好说明了这种模块边界的重要性。

参考文献

- [1] Kahneman, D., Tversky, A. “Prospect Theory: An Analysis of Decision under Risk.” *Econometrica*, 47(2), 263–291, 1979.
- [2] Hsee, C.K. “The Evaluability Hypothesis: An Explanation for Preference Reversals between Joint and Separate Evaluations of Alternatives.” *Organizational Behavior and Human Decision Processes*, 67(3), 247–257, 1996.
- [3] Joachims, T. “Optimizing Search Engines Using Clickthrough Data.” *KDD*, 133–142, 2002.

- [4] Burges, C., et al. “Learning to Rank Using Gradient Descent.” ICML, 89–96, 2005.
- [5] Rendle, S., et al. “BPR: Bayesian Personalized Ranking from Implicit Feedback.” UAI, 452–461, 2009.
- [6] Bengio, Y., et al. “Curriculum Learning.” ICML, 41–48, 2009.
- [7] Christiano, P., et al. “Deep Reinforcement Learning from Human Preferences.” NeurIPS, 2017.
- [8] Ouyang, L., et al. “Training Language Models to Follow Instructions with Human Feedback.” NeurIPS, 2022.
- [9] Michańków, J., Sakowski, P., Ślepaczuk, R. “Mean Absolute Directional Loss as a New Loss Function for Machine Learning Problems in Algorithmic Investment Strategies.” Journal of Computational Science, 2024. arXiv:2309.10546.
- [10] Michańków, J., Sakowski, P., Ślepaczuk, R. “Generalized Mean Absolute Directional Loss.” arXiv:2412.18405, 2024.
- [11] Lin, Y., Su, Y., Yang, Y. “LambdaRankIC: Directly Optimizing Rank IC for Financial Prediction.” arXiv:2605.00501, 2026.
- [12] Poh, D., et al. “Building Cross-Sectional Systematic Strategies By Learning to Rank.” Journal of Financial Data Science, 2024. arXiv:2012.07149.
- [13] Perez, E., et al. “FiLM: Visual Reasoning with a General Conditioning Layer.” AAAI, 2018.
- [14] Zhang, L., Rao, A., Agrawala, M. “Adding Conditional Control to Text-to-Image Diffusion Models.” ICCV, 2023.
- [15] Hounsby, N., et al. “Parameter-Efficient Transfer Learning for NLP.” ICML, 2019.
- [16] Hu, E.J., et al. “LoRA: Low-Rank Adaptation of Large Language Models.” ICLR, 2022.
- [17] Kakushadze, Z. “101 Formulaic Alphas.” arXiv:1601.00991, 2016.
- [18] Vaswani, A., et al. “Attention Is All You Need.” NeurIPS, 2017.
- [19] Chen, T., Guestrin, C. “XGBoost: A Scalable Tree Boosting System.” KDD, 2016.
- [20] Ke, G., et al. “LightGBM: A Highly Efficient Gradient Boosting Decision Tree.” NeurIPS, 2017.

A Feature Definitions

A.1 Stock Features (67-dimensional)

表A.1列出了 CLIME 使用的 67 维个股特征（索引 0–65（feat_1 至 feat_66）加上第 66 维位置编码，即 feat_1 至 feat_66 加上 lag_norm 位置编码），按 8 个类别分组。所有特征在每个交易日独立进行横截面 z-score 标准化。

表 A.1: 67 维个股特征定义。“cs_z” 前缀表示当日横截面 z-score 标准化。

Idx	Name	Category	Formula / Description
0	ret_1d	Returns	$\text{close}_t / \text{close}_{t-1} - 1$
1	ret_3d	Returns	$\text{close}_t / \text{close}_{t-3} - 1$
2	ret_5d	Returns	$\text{close}_t / \text{close}_{t-5} - 1$
3	ret_10d	Returns	$\text{close}_t / \text{close}_{t-10} - 1$
4	ret_20d	Returns	$\text{close}_t / \text{close}_{t-20} - 1$
5	log_ret_1d	Returns	$\ln(\text{close}_t / \text{close}_{t-1})$
6	intraday_return	Returns	$\text{close}_t / \text{open}_t - 1$
7	overnight_gap	Returns	$\text{open}_t / \text{close}_{t-1} - 1$
8	high_low_range	Price/Volume	$\text{high}_t / \text{low}_t - 1$
9	close_to_vwap	Price/Volume	$\text{close}_t / \text{vwap}_t - 1$
10	volume_log	Price/Volume	$\ln(1 + \text{vol}_t)$
11	amount_log	Price/Volume	$\ln(1 + \text{amount}_t)$
12	volume_ma5_ratio	Price/Volume	$\text{vol}_t / \text{mean}(\text{vol}_{t-5:t-1}) - 1$
13	amount_ma20_ratio	Price/Volume	$\text{amount}_t / \text{mean}(\text{amount}_{t-20:t-1}) - 1$
14	ma5_gap	Technical	$\text{close}_t / \text{MA5}_t - 1$
15	ma20_gap	Technical	$\text{close}_t / \text{MA20}_t - 1$
16	ma5_ma20_gap	Technical	$\text{MA5}_t / \text{MA20}_t - 1$
17	rolling_vol_20d	Technical	$\text{std}(\text{ret_1d}_{t-20:t-1})$
18	high_low_position_20d	Technical	$(\text{close}_t - \text{low}_{20}) / (\text{high}_{20} - \text{low}_{20})$
19	rsi_14	Technical	$100 \cdot \overline{\text{gain}}_{14} / (\overline{\text{gain}}_{14} + \overline{\text{loss}}_{14})$
20	macd_hist	Technical	$\text{EMA}_{12} - \text{EMA}_{26} - \text{EMA}_9(\text{EMA}_{12} - \text{EMA}_{26})$
21	bollinger_z_20d	Technical	$(\text{close}_t - \text{MA20}_t) / \text{std}_{20}$
22	turnover_rate	Fundamental	日换手率 (来自 metric 表)
23	volume_ratio	Fundamental	量比 (来自 metric 表)
24	pb	Fundamental	市净率 (来自 metric 表)
25	pe_ttm	Fundamental	滚动市盈率 (来自 metric 表)

表 A.1 (continued)

Idx	Name	Category	Formula / Description
26	ps_ttm	Fundamental	滚动市销率 (来自 metric 表)
27	log_total_mv	Fundamental	$\ln(1 + \text{total_mv})$
28	log_circ_mv	Fundamental	$\ln(1 + \text{circ_mv})$
29	net_mf_amount_ratio	MoneyFlow	$\text{net_mf_amount}/\text{amount}$
30	main_force_net_ratio	MoneyFlow	$(\text{buy_lg} + \text{buy_elg} - \text{sell_lg} - \text{sell_elg})/\text{amount}$
31	small_order_net_ratio	MoneyFlow	$(\text{buy_sm} - \text{sell_sm})/\text{amount}$
32	large_order_buy_ratio	MoneyFlow	$(\text{buy_lg} + \text{buy_elg})/\text{amount}$
33	large_order_sell_ratio	MoneyFlow	$(\text{sell_lg} + \text{sell_elg})/\text{amount}$
34	main_force_momentum_5d	MoneyFlow	$\text{mean}(\text{main_force_net_ratio}_{t-5:t-1})$
35	sh_ret_1d	Market Index	上证指数日收益率
36	sh_ret_5d	Market Index	上证指数 5 日收益率
37	hs300_ret_1d	Market Index	沪深 300 日收益率
38	hs300_ret_5d	Market Index	沪深 300 5 日收益率
39	cyb_ret_1d	Market Index	创业板指日收益率
40	cyb_ret_5d	Market Index	创业板指 5 日收益率
41	hs300_vol_20d	Market Index	沪深 300 20 日滚动波动率
42	hs300_ma5_ma20_gap	Market Index	沪深 300 MA5/MA20 - 1
43	hs300_drawdown_20d	Market Index	$\text{close}/\max_{20}(\text{close}) - 1$
44	market_avg_ret_1d	Market Breadth	全市场 ret_1d 横截面均值
45	market_median_ret_1d	Market Breadth	全市场 ret_1d 横截面中位数
46	market_advancing_ratio	Market Breadth	ret_1d > 0 的股票占比
47	market_cross_section_vol	Market Breadth	全市场 ret_1d 横截面标准差
48	market_top_bottom_spread	Market Breadth	top-20% 均值 - bottom-20% 均值
49	market_amount_change_5d	Market Breadth	全市场成交额 5 日变化率
50	cs_z_ret_5d	Cross-Sectional	ret_5d 横截面 z-score
51	cs_z_ret_20d	Cross-Sectional	ret_20d 横截面 z-score
52	cs_z_amount	Cross-Sectional	amount 横截面 z-score
53	cs_z_turnover_rate	Cross-Sectional	turnover_rate 横截面 z-score
54	cs_z_log_total_mv	Cross-Sectional	log_total_mv 横截面 z-score
55	cs_z_pb	Cross-Sectional	pb 横截面 z-score
56	cs_z_main_force_net_ratio	Cross-Sectional	main_force_net_ratio 横截面 z-score
57	cs_rank_ret_5d	Cross-Sectional	ret_5d 横截面百分位排名

表 A.1 (continued)

Idx	Name	Category	Formula / Description
58	cs_rank_amount	Cross-Sectional	amount 横截面百分位排名
59	cs_rank_main_force	Cross-Sectional	main_force_net_ratio 横截面百分位排名
60	industry_ret_1d	Industry	同行业 ret_1d 均值
61	industry_ret_5d	Industry	同行业 ret_5d 均值
62	relative_industry_ret_1d	Industry	ret_1d - industry_ret_1d
63	relative_industry_ret_5d	Industry	ret_5d - industry_ret_5d
64	industry_advancing_ratio	Industry	同行业 ret_1d > 0 占比
65	relative_industry_moneyflow	Industry	main_force_net_ratio - 行业均值
66	lag_norm	Positional	$[0, 1, \dots, L-1]/(L-1)$, 广播至所有时间步

A.2 Peer Dynamics Features (24-dimensional)

对于每只股票，基于多维度加权相似度（行业 0.30 + 业务名称 0.25 + 地区 0.10 + 市场 0.10 + 企业类型 0.10 + 20 日收益相关性 0.15）选取 top-10 最相似的同业股票，聚合得到 24 维同业动态特征。聚合所用原始特征来自最后时间步的 11 维指标：

{ret_1d, ret_5d, ret_20d, volume_log, amount_log, turnover_rate, rsi_14, macd_hist, bollinger_z_2

表 A.2: 24 维 Peer Dynamics 特征定义。“peer_*”表示对 top-10 同业的聚合统计量，“rel_*”表示个股值减去同业均值。

Idx	Name	Category	Aggregation
Peer Return Statistics (7)			
0	peer_mean_ret_1d	Return	Top-10 同业 ret_1d 均值
1	peer_mean_ret_5d	Return	Top-10 同业 ret_5d 均值
2	peer_mean_ret_20d	Return	Top-10 同业 ret_20d 均值
3	peer_std_ret_1d	Return	Top-10 同业 ret_1d 标准差
4	peer_std_ret_5d	Return	Top-10 同业 ret_5d 标准差
5	peer_std_ret_20d	Return	Top-10 同业 ret_20d 标准差
6	peer_spread_ret_1d	Return	Top-10 同业 ret_1d 极差 (max – min)
Volume & Activity (5)			
7	peer_mean_volume_log	Volume	Top-10 同业 volume_log 均值
8	peer_std_volume_log	Volume	Top-10 同业 volume_log 标准差
9	peer_mean_turnover	Activity	Top-10 同业 turnover_rate 均值
10	peer_std_turnover	Activity	Top-10 同业 turnover_rate 标准差
11	peer_mean_amount_log	Volume	Top-10 同业 amount_log 均值
Technical Indicators (4)			
12	peer_mean_rsi	Technical	Top-10 同业 rsi_14 均值
13	peer_mean_macd	Technical	Top-10 同业 macd_hist 均值
14	peer_std_macd	Technical	Top-10 同业 macd_hist 标准差
15	peer_mean_bollinger	Technical	Top-10 同业 bollinger_z_20d 均值
Fundamentals (2)			
16	peer_mean_pb	Fundamental	Top-10 同业 pb 均值
17	peer_mean_log_mv	Fundamental	Top-10 同业 log_total_mv 均值
Stock-vs-Peer Relative Deviation (6)			
18	rel_ret_1d	Relative	ret_1d – peer_mean_ret_1d
19	rel_ret_5d	Relative	ret_5d – peer_mean_ret_5d
20	rel_ret_20d	Relative	ret_20d – peer_mean_ret_20d
21	rel_volume	Relative	volume_log – peer_mean_volume_log
22	rel_turnover	Relative	turnover_rate – peer_mean_turnover
23	rel_rsi	Relative	rsi_14 – peer_mean_rsi

B Evaluation Details

B.1 Leakage Prevention Details

为避免前瞻偏差，数据管线中所有特征均按交易日 t 对齐，且只使用 t 日及以前可获得的信息。例如，20 日动量仅使用 $[t-19, t]$ 区间的历史收盘价，RSI-14 仅使用历史涨跌幅窗口，Peer Dynamics 也只基于 t 日可得的同业信息聚合。预测标签为 $t+1$ 日收益率，不参与任何特征计算。

横截面预处理同样逐日进行：缺失值以当日横截面中位数填充，极端值以当日 1% 和 99% 分位数 Winsorize，z-score 标准化仅使用当日全市场均值与标准差。我们没有使用跨日期标准化、全样本特征选择或任何 lookahead feature。

训练集、验证集和 holdout 按时间顺序严格切分。训练集截止于 2025 年 9 月 17 日，验证集从 2025 年 9 月 18 日开始，二者日历相邻但样本日期不重叠。训练集采用 $\text{step}=10$ 稀疏采样以降低相邻交易日高自相关对训练的影响；验证集与 holdout 采用 $\text{step}=1$ 全密度评估。2026 年 5 月 12 日至 5 月 26 日的 9 个交易日作为纯未来验证集，不参与训练、验证、holdout 评估或任何模型选择。

B.2 Differences from Real Trading

本文主实验的目标是隔离模型选股能力，因此回测协议相对理想化。真实 A 股交易至少还需要考虑以下因素：

- **交易成本和滑点：**A 股交易包含印花税、佣金和过户费等成本。每日调仓会带来较高换手，实际净收益会低于本文报告的模型信号收益。
- **涨跌停约束：**触及涨停的股票可能无法买入，触及跌停的股票可能无法卖出，极端行情下该限制会影响组合可执行性。
- **成交价格假设：**本文以 $t+1$ 日收盘收益评估信号，但实际交易中的开盘、盘中或收盘成交价格都会带来不同执行误差。
- **流动性约束：**对于小市值股票，等权 top-20 组合可能受到市场深度限制，真实资金规模越大，冲击成本越重要。
- **持有期设计：**本文采用单日持有和每日调仓；完整交易系统还需要选择持有期、换手约束和动态仓位管理。

因此，本文收益应被理解为选股排序信号的上限估计，而非完整交易系统的可实现净收益。

C Reproduction Guide

完整代码和模型权重可在 GitHub 获取：<https://github.com/wesleyfeil/CLIME>。

Environment Setup

```
git clone https://github.com/wesleyfei1/CLIME.git
cd CLIME/reconstruct_code
pip install -r requirements.txt
```

依赖: torch, numpy, pandas, scipy, tqdm, pyarrow。推荐使用 Python 3.10+ 和 CUDA 12.1+。

Data Preparation

将原始数据按以下结构放入 data/ 目录:

```
data/
|-- basic.csv           # 股票基础信息
|-- trade_cal.csv      # 交易日历
|-- daily/             # 个股日频行情 (YYYYMMDD.csv)
|-- daily_open/        # 开盘价数据
|-- metric/            # 基本面指标 (PE, PB, 换手率等)
|-- moneyflow/         # 资金流向 (大单/中单/小单)
|-- market/           # 市场指数 (上证, 沪深300, 创业板)
|-- index_weight/      # 指数成分股权重
|-- stock_st/          # ST 股票清单
`-- news/              # 新闻快讯
```

Build Feature Caches

1. 从原始数据计算标准化特征 parquet

```
python -c "
from src.data.loader import load_all
from src.data.features import compute_features
from src.data.preprocess import preprocess
raw = load_all('data')
features = compute_features(raw)
normalized = preprocess(features)
normalized.to_parquet('cache/normalized_features.parquet')
"
```

2. 构建特征序列缓存 (train/val/holdout)

```
python build_caches.py --split all
```

```
# 3. 构建 peer dynamics 缓存
python build_peer_dynamics.py
```

Train the Model

```
# Stage 1: Backbone 预训练 (pairwise ranking)
python train.py --stage1

# Stage 2: V9CA_AB 联合训练 (init_scale=0.3)
python train.py --v9ca-ab --init-scale 0.3 --epochs 25 \
  --stage1-ckpt output/transformer_v5/stage1_best.pt
```

训练完成后, 最佳模型保存于 `output/transformer_v5/transformer_v9ca_ab_is0p3_best.pt`。

Run Backtest

```
python backtest.py --v9ca-ab --split holdout_v5 \
  --v9ca-ab-ckpt output/transformer_v5/transformer_v9ca_ab_is0p3_best.pt \
  --stage1 output/transformer_v5/stage1_best.pt \
  --n 20
```

Daily Inference (Optional)

```
python daily_inference.py --date 20260530 \
  --model-path output/transformer_v5/transformer_v9ca_ab_is0p3_best.pt \
  --capital 1000000 --lambda-risk 0.3 --top-n 20
```

D Complete Hyperparameters

表D.1列出了 CLIME 训练和模型架构的全部超参数。

表 D.1: CLIME 完整超参数配置

Category	Hyperparameter	Value
Architecture		
	Backbone type	Transformer (Pre-LN)
	Input feature dim	67
	Hidden dim d	256
	Attention heads	8
	Transformer layers	4
	FFN hidden dim	1024

表 D.1 (continued)

Category	Hyperparameter	Value
	Position encoding	RoPE
	Aggregation	Last-token extraction
	Total params (Backbone)	$\sim 2.3\text{M}$
ScaledGatedEncoder		
	Peer dynamics dim	24
	Market context dim	8
	Encoder input dim	32 ($= 24 + 8$)
	Encoder hidden dim	256
	Encoder layers	3 (Linear $\rightarrow$ LN $\rightarrow$ ReLU)
	Gate network	$8 \rightarrow 64 \rightarrow 1 \rightarrow \sigma$
	Logit scale init	0.3 (optimized via grid search)
	Modulation formula	$h' = h + g \cdot \tanh(s) \cdot \frac{\mathbf{u}}{\ \mathbf{u}\ } \cdot \sqrt{256}$
	Total params (Encoder)	$\sim 0.5\text{M}$
Stage 1 —Pairwise Pretraining		
	Loss function	Pairwise Ranking Loss (softplus)
	Optimizer	Adam
	Learning rate	5×10^{-4}
	LR scheduler	CosineAnnealingLR, $T_{\max} = 40$
	Weight decay	10^{-5}
	Batch size	2048
	Max epochs	40
	Early stopping patience	10
	Gradient clip	1.0
	Pairs per day	5000
	Margin (min return diff)	0.002
Stage 2 —Three-Phase Curriculum		
	Optimizer	Adam
	LR scheduler	CosineAnnealingLR, $T_{\max} = 25$
	Weight decay	10^{-5}
	Batch size	256
	Max epochs	25
	Early stopping patience	8
	Gradient clip	1.0
	Samples per day	5000
Phase 1 (BCE Warmup, epochs 1-3)		
	Loss function	BCEWithLogitsLoss
	Backbone LR	0 (frozen)
	Encoder LR	10^{-3}
	Head LR	10^{-3}
Phase 2 (Core Training, epochs 4-15)		
	Loss function	Directional Regression Loss
	Loss α (sign error weight)	3.0
	Loss β (conservative reduction)	0.5
	Loss δ (Huber threshold)	0.01
	Backbone LR	10^{-5}
	Encoder LR	5×10^{-4}
	Head LR	5×10^{-4}
Phase 3 (Fine-tuning, epochs 16-25)		
	Loss function	Directional Regression Loss (same)
	Backbone LR	10^{-6}
	Encoder LR	5×10^{-5}
	Head LR	10^{-5}
Hardware		
	GPU	NVIDIA A100 80GB
	Training time (Stage 1)	~ 2 hours
	Training time (Stage 2)	~ 1.5 hours

E Model Version Evolution

表E.1记录了 CLIME 项目从 V5 到 V12 共 11 个版本的完整演进。评估均在 holdout_v5 (2025-12-05 至 2026-05-11, 100 个交易日) 上进行, Top-20 等权日调仓, 无交易成本¹。

表 E.1: CLIME 模型版本演进 (V5 $\rightarrow$ V12)。关键版本以**粗体**标出。

Ver.	Name	Key Change	Cum.	Excess	Sharpe
V5	Pure Transformer	Stage1 pairwise 预训练, 标准 Transformer Backbone, 无任何市场注入	+197.99%	+111.01%	5.77
V7	FiLM Modulation	引入 FiLM 乘性调制 ($\gamma \odot h + \beta$), 市场信号在 67 维特征空间注入	+127.70%	+40.72%	4.78
V7b	FiLM + Gate	在 V7 基础上增加 per-stock 门控, 控制调制强度	+99.20%	—	4.03
V8	Per-Feature Scale	67 个独立可学习 scale 参数逐维度缩放特征, 无 bottleneck 约束	+139.93%	+52.95%	5.19
V9	Market State (3 Principles)	确立三大设计原则: 256 维表征空间调制、信息 bottleneck、调制不主导	+20.12%	+4.97%	2.07
V9CA	Additive Injection	将乘性调制改为加性注入 ($h' = h + \alpha \cdot \text{offset}$), 架构突破	+95.84%	+80.69%	6.17
V9CA_AB is0.1	A+B Joint	加性注入 + per-stock gate + 全局可学习 scale, 初版	+148.44%	+133.29%	7.98
V9CA_AB is0.2	Scale Tuning (0.2)	init_scale 从 0.1 提升至 0.2	+148.47%	+133.32%	7.89
V9CA_AB is0.3	Scale Tuning (0.3), Best	init_scale = 0.3, 平衡 Backbone 保留与市场自适应: 0% 负月, maxDD 6.56%	+148.44%	+133.29%	7.98
V9CA_AB is0.5	Scale Tuning (0.5)	init_scale = 0.5, 市场信号过强, Backbone 表征开始被扭曲	+101.71%	+86.56%	5.49
V10	Market Context (8-dim)	新增 8 维市场上下文特征; encoder 几乎未使用, holdout 退化	+127.54%	+40.56%	4.91
V10B	Diversity Loss	加入多样性损失鼓励差异化门控; 从未激活 (threshold 过高), 训练不稳定	+19.00%	+3.85%	2.00
V11	Attention Pooling + 87-dim + Hard Mining	三项未经验证的改动一次堆叠: 注意力池化 (近乎随机)、87 维特征 (15/20 为噪声)、课程难例挖掘 (loss 跳涨 10 $\times$)。整个项目最有价值的反面教训	+10.56%	-4.59%	1.22
V12	Selected Features (abandoned)	尝试精选特征 + 修复 Factor Head Bias Collapse; 多轮迭代后回退至 V9 配置, 确认新特征来自 V11 (bad model) 引入噪声。最终放弃, 回归 V9CA_AB	+12.14%	-3.01%	1.44

Key Lessons from Version Evolution

1. 乘性调制是本问题的结构性陷阱: V7/V7b 的 FiLM 方案导致 holdout 从 +198% 骤降至 +128%/+99%。乘性调制 ($\gamma \odot h$) 不可逆地扭曲 Backbone 已学到的表征。

¹版本演进表中的评估协议与 RQ1 略有不同 (市场基准计算方式差异), 因此 V9CA_AB is0.3 在此处显示为 +148.44% 累计/+133.29% 超额, 而 RQ1 中为 +137.15% 累计/+123.14% 超额。两者均为正确的, 仅在市场等权基准的计算粒度上存在差异。

- 2. **加性注入是正确范式:** V9CA 将注入方式从乘法改为加法 ($h' = h + \text{offset}$), holdout 从 +20% 回升至 +96%, 为 V9CA_AB 的成功奠定基础。
- 3. **逐项验证是工程纪律:** V11 一次堆叠三项未经验证的改动, 直接导致模型报废 (holdout 仅 +10.56%, 超额转负)。此后每个改动单独验证, 再未犯过同类错误。
- 4. **init_scale 存在最优区间:** 0.1 $\rightarrow$ 0.3 逐步提升, 0.5 时开始退化——市场信号过强会侵蚀 Backbone 自身的判断力。

F Model Checkpoint Reference

表 F.1: 模型 checkpoint 索引

Checkpoint	File	Description
Stage1 Backbone	stage1_best.pt	Pairwise ranking 预训练权重
V9CA_AB is0.3	transformer_v9ca_ab_is0p3_best.pt	最优模型 (holdout +123.14% excess)
T1_MSE	ablation_t1_mse_best.pt	消融: MSE loss
T2_NoCur	ablation_t2_no_curriculum_best.pt	消融: 无 BCE 预热
T3_NoS1	ablation_t3_no_stage1_best.pt	消融: 无 Stage1 预训练
E1_NoEnc	ablation_e1_no_encoder_best.pt	消融: 无市场编码器

G Risk Predictor Configuration

表G.1列出了风险过滤器的完整配置。该过滤器在 CLIME 模型输出 alpha 分数后、构建投资组合前执行, 用于惩罚高波动、高回撤、低流动性的股票。

表 G.1: 风险预测器配置参数

Parameter	Value	Description
Risk Dimensions (all equal weight)		
vol_weight	1.0	Weight for 20-day realized volatility
dd_weight	1.0	Weight for 20-day max drawdown
amp_weight	1.0	Weight for 20-day mean daily amplitude
liq_weight	1.0	Weight for $-\log(1 + \text{mean_amount})$
Lookback	20 days	Rolling window for all risk metrics
Min periods	5 days	Minimum data required per stock
Combination		
Method	Cross-sectional z-score	$(x - \bar{x})/\sigma_x$ per (date, metric)
Z-score clipping	$\pm 3\sigma$	Clip z-scores to $[-3, 3]$ before summation
Final Scoring		
Formula	final = $z(\alpha) - \lambda \cdot z(\text{risk})$	
Risk aversion (λ)	0.3	Used only for simulated trading; main experiments use $\lambda = 0$
Two-Stage Filtering		
Alpha pool size	Top-10%	First filter by alpha score
Selection	Top-20	Re-rank within pool by final score

设计说明：该风险过滤器是规则驱动的工程组件，不包含任何可训练参数。4 个风险维度从原始 OHLCV 数据直接计算，通过横截面 z-score 标准化后等权组合。其目的是作为 CLIME 的工程补充而非核心学术贡献——模型训练和所有实验评估均使用纯 alpha 分数 ($\lambda = 0$)。

Risk cache 数据通过 pandas rolling 窗口在原始面板数据上预计算，存储于 `cache/risk_cache.pkl`，涵盖 `val_v5` 和 `holdout_v5` 的全部（日期，股票）对。推理和回测脚本通过加载此缓存文件获取风险分数。